

个人简介

计算机科学博士研究生 (CIFRE 产学研联合培养), 就读于索邦大学与 EURECOM, 并与华为巴黎研究所联合开展研究, 预计 2026 年底毕业。研究位于 AI、高性能计算 (HPC) 与机器学习系统 (MLSys) 交叉领域: 以符号化、优化驱动的规划器, 把超大规模混合并行 LLM/DNN 训练化为可预测、可移植的决策问题, 生成显存可行、通信感知的策略与流水线调度, 并在最多 16,384 张 Ascend NPU 的生产集群上验证。博士论文将其统一为一套可移植规划 workflow——预测、联合优化、重规划、自适应。

工作经历

华为巴黎研究所 — 分布式与并行计算实验室

法国, 巴黎

博士研究生 (CIFRE) 兼研究工程师 — 大模型训练系统

2021 — 2026 年底

- 构建基于代价模型的混合 / 流水线并行 LLM 训练规划器: 显存与性能约束下的阶段划分、流水线调度与重计算选择。
- 设计符号化峰值显存估计与集合通信代价模型, 结合通信-计算重叠, 进行大规模吞吐与 MFU 调优。
- 将研究原型产品化为可部署规划流程, 与工程及客户团队协作落地; 推动向生产级训练环境的技术转化。
- 建模 MoE / 专家并行与长序列训练: 专家归属约束、负载均衡, 以及序列 / 虚拟流水线调度。

角色演进: 研究学徒 (2021–2022) → 研究工程师 (2022–2023) → CIFRE 博士研究生 (2023–2026 年底)。

核心成果 (博士论文: 可移植规划 workflow, 覆盖七个并行维度)

- PRISM** (HPC Asia 2026, 可预测性 / 显存): 免性能采样地解析预测各阶段峰值显存与通信, 使显存可行性成为可移植、跨集群复用的闭式判断。
- BMPipe** (CLUSTER 2025, 流水线效率): 符号化气泡模型 + ILP 联合优化阶段边界 / 分块 / 重计算, 压缩空泡: 1.36 $\times$, HBM 83–92%, 验证至 16,384 张 Ascend NPU。
- H2O** (Euro-Par 2025 最佳海报奖, 全维度联合优化): 单一 workflow 联合优化所有并行维度 + 微批 + 自适应重计算; DeepSeek-141B 上 MFU 26.13%→35.73%, 并转生产。
- Concord** (审稿中 2026, 搜索效率 / 减少冗余): 依赖键控逐层签名只重算模型 / 配置改动失效的部分、复用其余, 避免冗余搜索。
- ManuMatic** (NPC 2025, 面向新算子的自适应): 将算子切分作为一等约束注入自动搜索, 对未建模的新算子 / 影响保持稳健; Qwen2.5-72B 上较专家方案 +30.1%。

论文与专利

论文 (第一 / 共同作者, 节选): BMPipe (IEEE CLUSTER 2025); H2O (Euro-Par 2025, 最佳海报奖); ManuMatic (NPC 2025); PRISM 与 MLLM Pipeline Bubble Modeling (HPC Asia 2026); Concord (依赖键控重规划, 审稿中 2026); Training Report of TeleChat3-MoE (arXiv:2512.24157)。

专利 (3 项): 机器学习模型执行计划生成 (WO 2025/020165 A1)、大模型负载均衡方法、大模型训练多维并行配置方法。

教育背景

索邦大学 & EURECOM — 计算机科学博士 (混合并行系统化与可移植优化; EDITE ED 130; 导师 Prof. Raja Appuswamy, Prof. Chong Li) 2023 — 2026 年底

索邦大学 — 计算机科学硕士 (算法、软件科学与技术) 2019 — 2022

巴黎-萨克雷大学 — 计算机科学学士 (早期研究受 Prof. Isabelle Guyon, Dr. Viviane Pons, Dr. Zhengying Liu 指导) 2016 — 2019

关键词

混合并行 · 流水线调度 · MoE / 专家并行 · 符号化代价与峰值显存建模 · ILP / MILP · 重计算 · 通信重叠 · MFU 优化 · Ascend NPU · 可移植

荣誉奖项

- | | |
|-------------------------------|---------|
| • 金奖, 华为自动负载均衡挑战令 | 2024.08 |
| • 最佳海报奖, Euro-Par 国际会议 | 2025.08 |
| • 感谢信, 中国电信 (DeepSeek-MoE 部署) | 2025.12 |

技能

编程: Python, C++, Java
框架 / 平台: MindSpore, PyTorch; 大规模 GPU/NPU 集群 (至 16k) 与云
工具 / 开发: Ascend 性能剖析, tracing、性能基准; Linux, Git
语言: 中文 (母语)、英语、法语、粤语