

个人简介

计算机科学博士研究生 (CIFRE 产学联合培养), 就读于索邦大学与 EURECOM, 并与华为巴黎研究所联合开展研究, 预计 2026 年底毕业。研究位于 AI、高性能计算 (HPC) 与机器学习系统 (MLSys) 交叉领域: 以符号化、优化驱动的规划器, 把超大规模混合并行 LLM/DNN 训练化为可预测、可移植的决策问题, 生成显存可行、通信感知的策略与流水线调度, 并在最多 16,384 张 Ascend NPU 的生产集群上验证。博士论文将其统一为一套可移植规划工作流——预测、联合优化、重规划、自适应。

工作经历

华为巴黎研究所 — 分布式与并行计算实验室

法国, 巴黎

博士研究生 (CIFRE) 兼研究工程师 — 大模型训练系统

2021 — 2026 年底

- 构建基于代价模型的混合并行训练规划器: 在多维并行空间中搜索并行度配置、阶段划分、流水线调度与重计算策略。
- 设计符号化峰值显存与集合通信代价模型, 支撑执行前的可行性判断与性能预测。
- 开展显存与性能分析及 profiling: 算子级性能剖析、显存 / 通信占用分析与瓶颈定位, 指导吞吐与 MFU 调优。
- 将研究原型产品化为可部署规划流程, 与工程及客户团队协作, 推动向生产级训练环境的技术转化。

角色演进: 研究学徒 (2021–2022) → 研究工程师 (2022–2023) → CIFRE 博士研究生 (2023–2026 年底)。

核心成果 (大模型可移植规划调优系统, 覆盖多种并行维度联合优化)

- PRISM** (HPC Asia 2026, 可预测性 / 显存): 免性能采样地解析预测各阶段峰值显存与通信, 使显存可行性成为可移植、跨集群复用的闭式判断。
- BMPipe** (CLUSTER 2025, 流水线效率): 符号化气泡模型 + ILP 联合优化阶段边界 / 分块 / 重计算, 压缩流水线空泡; 最高 1.36× 吞吐提升。
- H2O** (Euro-Par 2025 最佳海报奖, 全维度联合优化): 单一工作流联合优化所有并行维度 + 微批 + 自适应重计算, 并已转生产; MFU 26.13% → 35.73%。
- Concord** (审稿中 2026, 搜索效率 / 减少冗余): 依赖键控逐层签名只重算模型 / 配置改动失效的部分、复用其余, 避免冗余搜索。
- ManuMatic** (NPC 2025, 面向新算子的自适应): 将算子切分作为一等约束注入自动搜索, 对未建模的新算子 / 影响保持稳健, 在纯自动搜索退化处恢复优质方案。

论文与专利

论文: 第一作者 4 篇 (IEEE CLUSTER、Euro-Par 最佳海报奖、IFIP NPC、HPC Asia) + 1 篇在投; 合作 2 篇——MLLM Pipeline Bubble Modeling (HPC Asia 2026)、TeleChat3-MoE 训练报告 (arXiv:2512.24157)。完整列表见 Google Scholar。

专利 (3 项): 机器学习模型执行计划生成 (WO 2025/020165 A1)、大模型负载均衡方法、大模型训练多维并行配置方法。

教育背景

索邦大学 & EURECOM

2023 — 2026 年底

计算机科学博士 (混合并行系统化与可移植优化; 导师 Prof. Raja Appuswamy、Prof. Chong Li)

索邦大学

2019 — 2022

计算机科学硕士 (算法、软件科学与技术)

巴黎-萨克雷大学

2016 — 2019

计算机科学学士 (早期研究受 Prof. Isabelle Guyon、Dr. Viviane Pons、Dr. Zhengying Liu 指导)

关键词

混合并行 · 流水线调度 · MoE / 专家并行 · 符号化代价与峰值显存建模 · ILP / MILP · 重计算 · 通信重叠 · MFU 优化 · Ascend NPU · 可移植

荣誉奖项

- | | |
|------------------------------|---------|
| 金奖, 华为自动负载均衡挑战令 | 2024.08 |
| 最佳海报奖, Euro-Par 国际会议 | 2025.08 |
| 感谢信, 中国电信 (TeleChat3-MoE 部署) | 2025.12 |

技能

编程: Python、C++、Java
框架 / 平台: MindSpore、PyTorch; 大规模 GPU/NPU 集群 (至 16k) 与云
工具 / 开发: Ascend 性能剖析、tracing、性能基准; Linux、Git
语言: 中文、英语、法语、粤语