

个人简介

计算机科学博士研究生 (CIFRE 产学研联合培养), 就读于索邦大学与 EURECOM, 并与华为巴黎研究所联合开展研究, 预计 2026 年 8 月毕业。研究位于 AI、高性能计算 (HPC) 与机器学习系统 (MLSys) 交叉领域, 聚焦超大规模 LLM/DNN 训练的优化式策略规划: 以符号化性能 / 显存模型结合 ILP 与约束求解, 自动生成显存可行、通信感知的混合并行策略与流水线调度。成果发表于 CLUSTER、Euro-Par (最佳海报奖)、NPC、HPC Asia, 并在最多 16,384 张 Ascend NPU 的生产集群上验证落地。

工作经历

华为巴黎研究所 — 分布式与并行计算实验室

博士研究生 (CIFRE) 兼研究工程师 — 大模型训练系统

法国, 巴黎

2021 — 2026 (预计)

- 构建基于代价模型的混合 / 流水线并行 LLM 训练规划器: 显存与性能约束下的阶段划分、流水线调度与重计算选择。
- 设计符号化峰值显存估计与集合通信代价模型, 结合通信-计算重叠策略, 进行大规模吞吐与 MFU 调优。
- 将研究原型产品化为可部署规划流程, 与工程及客户团队协作落地; 推动研究向生产级训练环境的技术转化。

角色演进: 研究学徒 (2021-2022) → 研究工程师 (2022-2023) → CIFRE 博士研究生 (2023-2026)。

核心成果

- BMPipe** (CLUSTER 2025): 符号代价模型 + ILP 联合优化阶段边界 / 分块 / 重计算; 最高 $1.36\times$ 加速, HBM 利用率 83-92%, 验证至 16,384 张 Ascend NPU。
- ManuMatic** (NPC 2025): 算子切分作为一等规划约束; 相较 D-Rec 在 Mixtral-8 $\times$ 7B 上 $2.24\times$ 、Llama3-8B 上 $2.04\times$ 、Qwen2.5-72B 上较专家方案 +30.1%。
- H2O** (Euro-Par 2025 最佳海报奖): 两级规划工作流; MFU 26.13%→35.73%, DeepSeek-141B 加速 36.72%, 并转生产 (4,096 卡约 $1.1\times$, 512 卡长序列最高 $2.37\times$)。
- PRISM** (HPC Asia 2026): 免性能剖析的符号化规划器; $1.23\times$ - $1.43\times$ 加速, MFU 29.40%→36.20%, 验证至 1,024 卡。

论文与专利

论文 (第一/共同作者, 节选): BMPipe (IEEE CLUSTER 2025); H2O (Euro-Par 2025, 最佳海报奖); ManuMatic (NPC 2025); Training Report of TeleChat3-MoE (arXiv 2025); PRISM 与 MLLM Pipeline Bubble Modeling (HPC Asia 2026)。

专利: 3 项——机器学习模型执行计划生成 (WO 2025/020165 A1)、大模型负载均衡方法、大模型训练多维并行配置方法。

教育背景

索邦大学 & EURECOM —— 计算机科学博士 (导师: Prof. Raja Appuswamy, Prof. Chong Li)

2023 — 2026 (预计)

索邦大学 —— 计算机科学硕士 (算法、软件科学与技术)

2019 — 2022

巴黎-萨克雷大学 —— 计算机科学学士

2016 — 2019

荣誉奖项

- 金奖, 华为自动负载均衡挑战赛 2024.08
- 最佳海报奖, Euro-Par 国际会议 2025.08
- 感谢信, 中国电信 (DeepSeek-MoE 部署) 2025.12

技能

编程: Python、C++、Java
框架/平台: MindSpore、PyTorch; 大规模 GPU/NPU 集群与云
工具/开发: Ascend 性能剖析、tracing、性能基准; Linux、Git
语言: 中文 (母语)、英语、法语、粤语