

个人简介

计算机科学博士研究生（CIFRE 产学联合培养），就读于索邦大学与 EURECOM，并与华为巴黎研究所联合开展研究，预计 2026 年底毕业。研究位于人工智能（AI）、高性能计算（HPC）与机器学习系统（MLSys）交叉领域，设计符号化、优化驱动的规划器，把超大规模混合并行 LLM/DNN 训练化为可预测、可移植的决策问题——生成显存可行、通信感知的并行策略与流水线调度，并在最多 **16,384 张 Ascend NPU** 的生产集群上验证。已产出 4 篇第一作者论文（CLUSTER、Euro-Par 最佳海报、NPC、HPC Asia）、1 篇在投、合作的大规模 MoE 训练工作，以及 3 项专利，多项已转化到生产。

博士研究

博士论文：《面向大规模分布式训练的混合并行系统化与可移植优化》（索邦大学）。以单一的逐层（Transformer）代价单元构建可移植的“行为级”规划 workflow，覆盖全部七个并行维度（数据 / 张量 / 流水线 / 虚拟流水线 / 序列 / 专家 / 优化器），使大规模混合并行规划具备**可预测性**（PRISM）、**互操作性**（BMPipe + H2O）、**可演进性**（Concord）与**自适应性**（ManuMatic）。该单元将模型、硬件与并行描述解耦，使方案在执行前即可预测、并可跨 GPU/NPU 集群移植；已在 Mixtral-8×7B、Llama3-8B、Qwen2.5-72B、DeepSeek-141B 等模型、从数十卡到 16,384 张 Ascend NPU 集群（含长序列场景）上验证。

代表系统与成果

- PRISM** —— **以符号化显存建模实现可预测性**（HPC Asia 2026）：免性能采样的层级代价曲面，直接从模型、训练配置与硬件描述解析预测各阶段峰值显存与通信，把显存可行性从反复试错变为可移植、可跨 GPU/NPU 集群复用的闭式判断。
- BMPipe** —— **主攻流水线效率**（IEEE CLUSTER 2025）：以符号化气泡模型（重计算 / 阶段不均衡 / 预备气泡）结合 ILP，联合确定阶段边界、阶段内分块与逐层重计算，压缩流水线空泡；吞吐最高 $1.36\times$ 。
- H2O** —— **全维度联合优化**（Euro-Par 2025 最佳海报奖）：在单一 workflow 中联合优化各并行维度的并行度、微批大小与自适应重计算，而非逐项分别调参，并已转化到生产训练；MFU $26.13\% \rightarrow 35.73\%$ 。
- Concord** —— **以复用提升搜索效率**（审稿中 2026）：依赖键控的逐层签名精确定位模型 / 配置改动所失效的规划部分，使重规划只重算失效项、复用其余有效结果，避免冗余搜索，加速模型与策略的迭代协同设计。
- ManuMatic** —— **面向新算子与运行时影响的自适应**（NPC 2025）：将用户 / 运行时指定的算子切分作为一等约束注入自动搜索，当出现抽象模型未覆盖的新算子或新影响时仍保持稳健，在纯自动搜索退化处恢复优质方案。

工作经历

华为巴黎研究所 — 分布式与并行计算实验室

法国，巴黎

博士研究生（CIFRE）兼研究工程师 — 大模型训练系统

2021 — 2026 年底

- 构建基于代价模型的混合并行 LLM 训练规划器：在多维并行空间中搜索并行度配置、阶段划分、流水线调度与重计算策略。
- 设计符号化峰值显存与集合通信代价模型，支撑执行前的可行性判断与性能预测。
- 开展显存与性能分析及 profiling：算子级性能剖析、显存 / 通信占用分析与瓶颈定位，指导吞吐与 MFU 调优。
- 沉淀可调试执行轨迹与跨模型 / 跨规模的回归基准，支撑可复现的评测与配置建议。
- 将研究原型产品化为可部署规划流程，与工程及客户团队协作，推动向生产级训练环境的技术转化。

角色演进：研究学徒（2021–2022）→ 研究工程师（2022–2023）→ CIFRE 博士研究生（2023–2026 年底）。

生产落地与协作

- 将规划器生成的策略转化到生产训练：4,096 卡训练端到端约 $1.1\times$ ，512 卡长序列训练最高 $2.37\times$ 。
- 参与大规模 TeleChat3-MoE 训练优化的部署，在真实客户负载与超大规模集群上形成反馈闭环。
- 跨研究、工程与客户平台团队协作；构建可复现的基准测试与可调试轨迹，使规划决策在生产中可信。

论文发表

1. **Ruiwen Wang**, Chong Li, Thibaut Tachon, Raja Appuswamy, Teng Su. *BMPipe: Bubble-Memory Co-optimization Strategy Planner for Very-Large DNN Training*. IEEE CLUSTER 2025.

2. **Ruiwen Wang**, Chong Li, Raja Appuswamy, Yujie Yuan. *H2O: Holistic Hyperparameter Optimization for Large-Scale Deep Neural Network Training*. Euro-Par 2025. (最佳海报奖 / Best Poster Award)

3. **Ruiwen Wang**, Chong Li, Hongxing Wang, Raja Appuswamy, Yujie Yuan. *ManuMatic: Strategy Injection for Robust Automatic Hybrid Parallelism in Distributed DNN Training*. NPC 2025.

4. **Ruiwen Wang**, Philippe Fang, Chong Li, Thibaut Tachon, Raja Appuswamy. *PRISM: Profiling-Free Symbolic Memory-Driven Strategy Planner for Large DNN Model Training*. HPC Asia 2026.

5. **Ruiwen Wang**, Thibaut Tachon, Chong Li, Raja Appuswamy. *Can Hybrid-Parallel Planning Support Alternating Model-Strategy Design? Dependency-Keyed Per-Layer Primitives for Re-Planning*. (审稿中 / under submission, 2026)

6. Zhengdao Yu, **Ruiwen Wang**, Nelson Lossing, Chong Li. *MLLM Pipeline Bubble Modeling for Large-Scale Training*. HPC Asia 2026.

7. Xinzhang Liu, Chao Wang, Zhihua Yang, Zhuo Jiang, **Ruiwen Wang**, et al. *Training Report of TeleChat3-MoE*. arXiv:2512.24157, 2025.

专利

1. Chong Li, Pierre Leca, Thibaut Tachon, **Ruiwen Wang**, Haoran Wang. *Devices and methods for generating execution plans for a machine learning model*. (WO 2025/020165 A1)

2. Chong Li, **Ruiwen Wang**, Haoran Wang, Fan Yu. *A load balancing method to improve large model performance*.

3. Chong Li, Thibaut Tachon, **Ruiwen Wang**, Haoran Wang. *A multi-dimension parallelism configuration method for large language model training*.

教育背景

索邦大学 & EURECOM	法国，巴黎
计算机科学博士；导师：Prof. Raja Appuswamy、Prof. Chong Li	2023 — 2026 年底
▪ 博士论文：面向大规模分布式训练的混合并行系统化与可移植优化。	
索邦大学	法国，巴黎
计算机科学硕士 — 算法、软件科学与技术；导师：Prof. Emmanuel Chailloux、Prof. Jacques Malenfant	2019 — 2022
巴黎-萨克雷大学	法国，巴黎
计算机科学学士	2016 — 2019
▪ 早期研究受 Prof. Isabelle Guyon、Dr. Viviane Pons、Dr. Zhengying Liu 指导。	

关键词

混合并行 · 流水线调度 · MoE / 专家并行 · 符号化代价与峰值显存建模 · ILP / MILP 规划 · 重计算 · 通信重叠 · MFU 优化 · Ascend NPU · 可移植 / 重定向

荣誉奖项

▪ 金奖，华为自动负载均衡挑战令 (Huawei Challenge Award)	2024.08
▪ 最佳海报奖，Euro-Par 国际会议	2025.08
▪ 感谢信，中国电信 (TeleChat3-MoE 部署)	2025.12

技能

并行：数据、张量、流水线、虚拟流水线、序列、专家、优化器	机器学习框架：MindSpore、PyTorch
优化：ILP / MILP、约束规划、符号化代价与峰值显存建模	平台：大规模 GPU / NPU 集群（至 16k）与云
编程语言：Python、C++、Java	工具 / 开发：Ascend 性能剖析、tracing、性能回归基准；Linux、Git