

个人简介

计算机科学博士研究生 (CIFRE 产学研联合培养), 就读于索邦大学 (Sorbonne University) 与 EURECOM, 并与华为巴黎研究所联合开展研究, 预计 2026 年 8 月毕业。研究方向位于人工智能 (AI)、高性能计算 (HPC) 与机器学习系统 (MLSys) 的交叉领域, 聚焦于面向超大规模 LLM/DNN 训练的高效、可靠的优化式策略规划。构建符号化的性能与显存模型, 并结合整数线性规划 (ILP) 与约束求解, 自动生成显存可行、通信感知的混合并行策略与流水线调度方案。研究成果发表于 CLUSTER、Euro-Par (最佳海报奖)、NPC、HPC Asia 等会议, 并在最多 16,384 张 Ascend NPU 的生产集群上完成验证, 已转化为可落地的规划流程, 连接系统底层研究与真实训练基础设施。

研究专长

- 可扩展 LLM/DNN 训练系统: 张量 / 数据 / 流水线 / 专家混合并行策略设计、阶段划分、微批次调度。
- 系统协同优化的原理性建模: 符号化性能与峰值显存建模、可行性分析、大规模集群验证方法。
- 优化式规划算法: 以约束规划与整数线性规划联合优化显存、通信与吞吐。
- 科研到生产的转化: 可复现的基准测试与可部署流程, 与工程及平台团队协作落地。

工作经历

华为巴黎研究所 — 分布式与并行计算实验室

博士研究生 (CIFRE) 兼研究工程师 — 大模型训练系统

法国, 巴黎

2021 — 2026 (预计)

- 构建基于代价模型的混合 / 流水线并行 LLM 训练规划器: 在显存与性能约束下完成阶段划分、流水线调度与重计算选择。
- 设计符号化峰值显存估计与集合通信代价模型, 结合通信-计算重叠策略, 进行大规模吞吐与 MFU 调优。
- 将研究原型产品化为可部署的规划流程, 与工程及客户团队协作, 提供可操作的配置建议、可调试的执行轨迹与跨模型 / 跨规模的回归基准。
- 推动研究成果向生产级训练环境的技术转化, 包括在客户负载与长序列训练场景中的部署反馈闭环。

角色演进: 研究学徒 (2021-2022) → 研究工程师 (2022-2023) → CIFRE 博士研究生 (2023-2026)。

代表性成果

BMPipe: 流水线气泡-显存协同优化规划器 (CLUSTER 2025)

2023 — 2024

- 以符号代价模型结合 ILP 搜索, 联合优化阶段边界、阶段内分块与逐层重计算; 最高 $1.36\times$ 加速, HBM 利用率 83-92%, 在最多 16,384 张 Ascend NPU 集群上验证。

ManuMatic: 面向稳健自动混合并行的策略注入 (NPC 2025)

2024

- 将用户提供的算子切分作为一等规划约束, 实现稳健的“手动 + 自动”搜索; 相较 D-Rec 在 Mixtral-8 $\times$ 7B 上 $2.24\times$ 、Llama3-8B 上 $2.04\times$, 在 Qwen2.5-72B 上较专家调优方案提升 30.1%。

H2O: 两级规划与部署工作流 (Euro-Par 2025 最佳海报奖)

2025

- 先搜索并行度与微批大小, 再细化层-阶段映射与自适应重计算; 将 MFU 从 26.13% 提升至 35.73%, 在 DeepSeek-141B 上加速 36.72%, 并转化到生产部署 (4,096 卡训练约 $1.1\times$, 512 卡长序列训练最高 $2.37\times$)。

PRISM: 免性能剖析的符号化策略规划器 (HPC Asia 2026)

2025

- 无需性能采样即可预测峰值显存与通信, 并在统一目标下搜索混合并行策略; $1.23\times$ - $1.43\times$ 加速, MFU 从 29.40% 提升至 36.20%, 在最多 1,024 卡上验证。

论文发表

- Ruiwen Wang, Chong Li, Thibaut Tachon, Raja Appuswamy, Teng Su. BMPipe: Bubble-Memory Co-optimization Strategy Planner for Very-Large DNN Training. IEEE CLUSTER 2025.
- Ruiwen Wang, Chong Li, Raja Appuswamy, Yujie Yuan. H2O: Holistic Hyperparameter Optimization for Large-Scale Deep Neural Network Training. Euro-Par 2025. (最佳海报奖 / Best Poster Award)
- Ruiwen Wang, Chong Li, Hongxing Wang, Raja Appuswamy, Yujie Yuan. ManuMatic: Strategy Injection for Robust Automatic Hybrid Parallelism in Distributed DNN Training. NPC 2025.
- Xinzhong Liu, Chao Wang, Zhihua Yang, Zhuo Jiang, Ruiwen Wang, et al. Training Report of TeleChat3-MoE. arXiv preprint, 2025.
- Ruiwen Wang, Philippe Fang, Chong Li, Thibaut Tachon, Raja Appuswamy. PRISM: Profiling-Free Symbolic Memory-Driven Strategy Planner for Large DNN Model Training. HPC Asia 2026.
- Zhengdao Yu, Ruiwen Wang, Nelson Lossing, Chong Li. MLLM Pipeline Bubble Modeling for Large-Scale Training. HPC Asia 2026.

专利

- Chong Li, Pierre Leca, Thibaut Tachon, **Ruiwen Wang**, Haoran Wang. *Devices and methods for generating execution plans for a machine learning model*. (WO 2025/020165 A1)
- Chong Li, **Ruiwen Wang**, Haoran Wang, Fan Yu. *A load balancing method to improve large model performance*.
- Chong Li, Thibaut Tachon, **Ruiwen Wang**, Haoran Wang. *A multi-dimension parallelism configuration method for large language model training*.

教育背景

索邦大学 & EURECOM

计算机科学博士；导师：Prof. Raja Appuswamy、Prof. Chong Li

法国，巴黎
2023 — 2026（预计）

- 研究课题：使用并行计算技术实现分布式学习的系统化与可移植加速。

索邦大学

计算机科学硕士；导师：Prof. Emmanuel Chailloux、Prof. Jacques Malenfant

法国，巴黎
2019 — 2022

- 方向：算法、软件科学与技术。

巴黎-萨克雷大学 — 计算机科学学士（法国，巴黎）

2016 — 2019

荣誉奖项

- 金奖，华为自动负载均衡挑战赛（Huawei Challenge Award）2024.08
- 最佳海报奖，Euro-Par 国际会议 2025.08
- 感谢信，中国电信（DeepSeek-MoE 训练优化部署）2025.12

技能

编程语言：Python、C++、Java

机器学习框架：MindSpore、PyTorch

平台：大规模 GPU/NPU 集群与云

工具：Ascend 性能剖析、tracing、性能回归基准测试

开发：Linux、Git

语言：中文（母语）、英语（流利）、法语（流利）、粤语