

个人简介

计算机科学博士研究生 (CIFRE 产学联合培养), 就读于索邦大学与 EURECOM, 并与华为巴黎研究所联合开展研究, 预计 2026 年底毕业。研究位于人工智能 (AI)、高性能计算 (HPC) 与机器学习系统 (MLSys) 交叉领域, 设计符号化、优化驱动的规划器, 把大规模混合并行 LLM/DNN 训练化为可预测、可移植的决策问题——生成显存可行、通信感知的并行策略与流水线调度, 并在最多 16,384 张 Ascend NPU 的生产集群上验证。已产出 4 篇第一作者论文 (CLUSTER、Euro-Par 最佳海报、NPC、HPC Asia)、1 篇在投、合作的大规模 MoE 训练工作, 以及 3 项专利, 多项已转化到生产。

博士研究

博士论文:《面向大规模分布式训练的混合并行系统化与可移植优化》(索邦大学, EDITE ED 130 博士学院)。以单一的逐层 (Transformer) 代价单元构建可移植的“行为级”规划工作流, 覆盖全部七个并行维度 (数据 / 张量 / 流水线 / 虚拟流水线 / 序列 / 专家 / 优化器), 使大规模混合并行规划具备**可预测性** (PRISM)、**互操作性** (BMPipe + H2O)、**可演进性** (Concord) 与**自适应性** (ManuMatic)。该单元将模型、硬件与并行描述解耦, 使方案在执行前即可预测、并可跨 GPU/NPU 集群移植; 已在 Mixtral-8×7B、Llama3-8B、Qwen2.5-72B、DeepSeek-141B 等模型、从数十卡到 16,384 张 Ascend NPU 集群 (含长序列场景) 上验证。

代表系统与成果

- PRISM** —— **以符号化显存建模实现可预测性** (HPC Asia 2026): 免性能采样的层级代价曲面, 直接从模型、训练配置与硬件描述解析预测各阶段峰值显存与通信, 把显存可行性从反复试错变为可移植、可跨 GPU/NPU 集群复用的闭式判断。
- BMPipe** —— **主攻流水线效率** (IEEE CLUSTER 2025): 以符号化气泡模型 (重计算 / 阶段不均衡 / 预备气泡) 结合 ILP, 联合确定阶段边界、阶段内分块与逐层重计算, 压缩流水线空泡; 吞吐最高 1.36×, HBM 利用率 83–92%, 验证至 16,384 张 Ascend NPU。
- H2O** —— **全维度联合优化** (Euro-Par 2025 最佳海报奖): 在单一工作流中联合优化各并行维度的并行度、微批大小与自适应重计算, 而非逐项分别调参; DeepSeek-141B 上 MFU 26.13%→35.73%, 并已转化到生产训练。
- Concord** —— **以复用提升搜索效率** (审稿中 2026): 依赖键控的逐层签名精确定位模型 / 配置改动所失效的规划部分, 使重规划只重算失效项、复用其余有效结果, 避免冗余搜索, 加速模型与策略的迭代协同设计。
- ManuMatic** —— **面向新算子与运行时影响的自适应** (NPC 2025): 将用户 / 运行时指定的算子切分作为一等约束注入自动搜索, 当出现抽象模型未覆盖的新算子或新影响时仍保持稳健; 在纯自动搜索退化处恢复优质方案 (如 Qwen2.5-72B 上较专家调优方案 +30.1%)。

工作经历

华为巴黎研究所 — 分布式与并行计算实验室

博士研究生 (CIFRE) 兼研究工程师 — 大模型训练系统

法国, 巴黎

2021 — 2026 年底

- 构建基于代价模型的混合 / 流水线并行 LLM 训练规划器: 在显存与性能约束下完成阶段划分、流水线调度与重计算选择。
- 设计符号化峰值显存估计与集合通信代价模型, 结合通信-计算重叠策略, 进行大规模吞吐与 MFU 调优。
- 将研究原型产品化为可部署的规划流程, 与工程及客户团队协作: 配置建议、可调试执行轨迹与跨模型 / 跨规模的回归基准。
- 推动研究成果向生产级训练环境转化, 包括客户负载与长序列训练的部署反馈 (中国电信就 DeepSeek-MoE 优化致感谢信)。
- 建模 MoE / 专家并行与长序列训练: 专家归属约束、负载均衡, 以及序列 / 虚拟流水线调度。

角色演进: 研究学徒 (2021–2022) → 研究工程师 (2022–2023) → CIFRE 博士研究生 (2023–2026 年底)。

生产落地与协作

- 将规划器生成的策略转化到生产训练: 4,096 卡训练端到端约 1.1×, 512 卡长序列训练最高 2.37×。
- 参与大规模 DeepSeek-MoE 训练优化的部署, 在真实客户负载与超大规模集群上形成反馈闭环。

- 跨研究、工程与客户平台团队协作；构建可复现的基准测试与可调试轨迹，使规划决策在生产中可信。

论文发表

1. **Ruiwen Wang**, Chong Li, Thibaut Tachon, Raja Appuswamy, Teng Su. *BMPipe: Bubble-Memory Co-optimization Strategy Planner for Very-Large DNN Training*. IEEE CLUSTER 2025.
2. **Ruiwen Wang**, Chong Li, Raja Appuswamy, Yujie Yuan. *H2O: Holistic Hyperparameter Optimization for Large-Scale Deep Neural Network Training*. Euro-Par 2025. (最佳海报奖 / Best Poster Award)
3. **Ruiwen Wang**, Chong Li, Hongxing Wang, Raja Appuswamy, Yujie Yuan. *ManuMatic: Strategy Injection for Robust Automatic Hybrid Parallelism in Distributed DNN Training*. NPC 2025.
4. **Ruiwen Wang**, Philippe Fang, Chong Li, Thibaut Tachon, Raja Appuswamy. *PRISM: Profiling-Free Symbolic Memory-Driven Strategy Planner for Large DNN Model Training*. HPC Asia 2026.
5. **Ruiwen Wang**, Thibaut Tachon, Chong Li, Raja Appuswamy. *Can Hybrid-Parallel Planning Support Alternating Model-Strategy Design? Dependency-Keyed Per-Layer Primitives for Re-Planning*. (审稿中 / under submission, 2026)
6. Zhengdao Yu, **Ruiwen Wang**, Nelson Lossing, Chong Li. *MLLM Pipeline Bubble Modeling for Large-Scale Training*. HPC Asia 2026.
7. Xinzhang Liu, Chao Wang, Zhihua Yang, Zhuo Jiang, **Ruiwen Wang**, et al. *Training Report of TeleChat3-MoE*. arXiv:2512.24157, 2025.

专利

1. Chong Li, Pierre Leca, Thibaut Tachon, **Ruiwen Wang**, Haoran Wang. *Devices and methods for generating execution plans for a machine learning model*. (WO 2025/020165 A1)
2. Chong Li, **Ruiwen Wang**, Haoran Wang, Fan Yu. *A load balancing method to improve large model performance*.
3. Chong Li, Thibaut Tachon, **Ruiwen Wang**, Haoran Wang. *A multi-dimension parallelism configuration method for large language model training*.

教育背景

索邦大学 & EURECOM

法国，巴黎

计算机科学博士 — EDITE ED 130 博士学院；导师：Prof. Raja Appuswamy、Prof. Chong Li

2023 — 2026 年底

• 博士论文：面向大规模分布式训练的混合并行系统化与可移植优化。

索邦大学

法国，巴黎

计算机科学硕士 — 算法、软件科学与技术；导师：Prof. Emmanuel Chailloux、Prof. Jacques Malenfant

2019 — 2022

巴黎-萨克雷大学

法国，巴黎

计算机科学学士

2016 — 2019

• 早期研究受 Prof. Isabelle Guyon、Dr. Viviane Pons、Dr. Zhengying Liu 指导。

关键词

混合并行 · 流水线调度 · MoE / 专家并行 · 符号化代价与峰值显存建模 · ILP / MILP 规划 · 重计算 · 通信重叠 · MFU 优化 · Ascend NPU · 可移植 / 重定向

荣誉奖项

- 金奖，华为自动负载均衡挑战令 (Huawei Challenge Award) 2024.08
- 最佳海报奖，Euro-Par 国际会议 2025.08
- 感谢信，中国电信 (DeepSeek-MoE 训练优化部署) 2025.12

技能

并行：数据、张量、流水线、虚拟流水线、序列、专家、优化器

机器学习框架：MindSpore、PyTorch

优化：ILP / MILP、约束规划、符号化代价与峰值显存建模

平台：大规模 GPU / NPU 集群（至 16k）与云

编程语言：Python、C++、Java

工具 / 开发：Ascend 性能剖析、tracing、性能回归基准；Linux、Git